

# 多源数据融合挖掘在房价预测中的应用研究

陈晓英\* 孙钰淼† 石韞嘉‡ 潘志强§

同济大学计算机科学与技术学院

指导教师：赵钦佩、饶卫雄

2026 年 6 月

## 摘要

房价预测是数据挖掘与机器学习领域中的典型回归任务。传统房价预测方法通常主要依赖结构化房屋属性，例如房屋面积、卧室数量、浴室数量、房屋类型、车库数量、建造年份和地理位置等。然而，在真实房源数据中，房源描述文本同样包含大量有价值的信息，例如装修情况、社区环境、景观条件、交通便利性、学校资源、房屋卖点等。这些信息往往无法完全通过结构化字段表达，但会影响购房者对房屋价值的判断。因此，将结构化数据与非结构化文本数据进行融合，有助于更全面地刻画房屋特征，提高房价预测模型的准确性。

本项目围绕“多源数据融合挖掘”主题，以房价预测为研究任务，构建了一个融合结构化房屋属性数据与房源描述文本数据的多模态预测系统。项目以 Florida Real Estate Sold 数据集为主要实验数据，对原始房源数据进行了结构化预处理、文本清洗、TF-IDF 特征提取、BERT 语义向量提取，并分别构建了结构化基线模型、文本基线模型、早期融合模型、中期融合模型和晚期融合模型。实验共训练并评估 9 个模型，评价指标包括 RMSE、MAE、 $R^2$  和 MAPE。

实验结果表明，多源融合模型整体优于单一数据源模型。其中，**EarlyFusionMLP** 在测试集上取得最优表现，Test RMSE 为 107,725.39，Test MAE 为 71,498.85，Test  $R^2$  为 0.8447。相比表现最好的单模态结构化模型 LinearBaseline (Test RMSE = 138,423.67)，EarlyFusionMLP 的测试集 RMSE 降低约 22.0%， $R^2$  提升约 0.101。结果说明，房源文本描述虽然单独建模效果有限，但与结构化房屋属性融合后能够提供额外信息，从而显著提升预测性能。Wilcoxon 配对符号秩检验结果 ( $p < 0.001$ ) 验证了上述提升具有统计显著性。

\*数据工程负责人

†算法负责人

‡评估与分析负责人

§工程与交付负责人

在工程实现方面,本项目完成了从数据预处理、特征工程、模型训练、模型评估到实验结果输出的端到端流程,并新增统一 Pipeline 入口。项目完整代码已开源:<https://github.com/steve26456d/multi-source-house-price-prediction>。

**关键词:** 房价预测; 多源数据融合; BERT; TF-IDF; 早期融合; 深度学习

# 1 引言

## 1.1 研究背景

房价预测是房地产分析、金融风控、城市规划和智能推荐系统中的重要问题。准确预测房价不仅可以帮助购房者和卖房者了解市场价格，也可以辅助房地产平台进行价格评估、房源排序和投资分析。从数据挖掘角度看，房价预测属于典型的监督学习回归任务，其目标是根据房屋相关特征预测连续型价格变量。

传统房价预测模型通常使用结构化表格数据作为输入，例如房屋面积、卧室数量、浴室数量、建造年份、邮编、房屋类型、车库数量等。这类数据具有格式统一、易于清洗、适合机器学习建模等优点，因此在线性回归、随机森林、梯度提升树等模型中被广泛使用。

然而，真实房源数据不仅包含结构化字段，还包含大量文本描述。例如，一套房源可能在描述中提到“newly renovated kitchen”“lake view”“close to school”“quiet neighborhood”“luxury community”等信息。这些描述往往体现了房屋的环境价值、装修质量、生活便利性和潜在卖点，但它们无法完全通过结构化字段反映出来。因此，仅依赖结构化数据可能会损失部分重要信息。

随着自然语言处理技术的发展，文本特征可以通过 TF-IDF、词向量、BERT 等方法转化为可用于建模的数值向量。将文本特征与结构化特征进行融合，可以更全面地表示房源信息，这正是多源数据融合在房价预测任务中的应用价值。

## 1.2 研究问题

本项目主要围绕以下问题展开：

- (1) 单独使用结构化房屋属性数据时，模型能够达到怎样的预测效果？
- (2) 单独使用房源描述文本特征时，模型表现如何？
- (3) 将结构化特征和文本特征融合后，是否能够提升房价预测性能？
- (4) 早期融合、中期融合和晚期融合三种策略在本任务中的效果有何差异？
- (5) 如何将数据处理、模型训练和评估流程整合成可复现、可运行的端到端 Pipeline？

## 1.3 项目目标

本项目的目标包括以下几个方面：

首先，完成多源房价数据的预处理和特征提取，包括结构化特征处理、文本清洗、TF-IDF 特征提取和 BERT 语义向量提取。其次，构建多种单模态基线模型和多源融合模型，并通过统一评价指标进行对比分析。再次，验证结构化数据与文本数

据融合对房价预测任务的提升作用。最后，完成工程化整合，使项目能够通过统一命令完成检查、训练、评估和结果输出。

## 2 数据集与数据预处理

### 2.1 数据来源

本项目使用的核心数据集为：

表 1: 项目使用的数据集

| 数据集                           | 样本数    | 数据模态         | 用途         |
|-------------------------------|--------|--------------|------------|
| Florida Real Estate Sold 2026 | 10,893 | 结构化数据 + 文本数据 | 多源融合主实验数据集 |

Florida Real Estate Sold 2026 是本项目多源融合实验的核心数据集。该数据集同时包含房屋结构化属性和房源描述文本，适合用于验证结构化数据与文本数据融合在房价预测任务中的效果。

本次完整 Pipeline 实验实际使用的是 Florida 数据集。真实数据运行时，系统读取以下三个处理后文件：

```
data/processed/florida_structured.csv
data/processed/florida_tfidf_features.pkl
data/processed/florida_bert_embeddings.pkl
```

其中,florida\_structured.csv 保存结构化特征及目标变量,florida\_tfidf\_features.pkl 保存 TF-IDF 降维后的文本特征，florida\_bert\_embeddings.pkl 保存 BERT 提取的文本语义向量。

### 2.2 目标变量

本项目的预测目标为房屋最终成交价格 lastSoldPrice。该字段表示房屋的最终出售价格，是模型需要预测的连续型数值变量。

### 2.3 结构化数据预处理

结构化数据预处理主要由 src/data/preprocess\_structured.py 完成。处理步骤包括缺失值填补、异常值处理、类别变量编码和数值特征标准化。

### 2.3.1 缺失值处理

对于数值型字段，使用中位数进行填补。中位数相比均值对极端值更稳健，适合房价、面积等可能存在长尾分布的变量。对于类别型字段，使用众数进行填补，保证类别变量在编码前不存在空值，避免后续 One-Hot 编码或模型训练时报错。

### 2.3.2 异常值处理

项目使用 IQR 方法对部分关键数值字段进行异常值处理。IQR 方法根据四分位数计算异常范围，常用保留区间为  $[Q_1 - 1.5 \times IQR, Q_3 + 1.5 \times IQR]$ 。本项目主要对 `listPrice`、`lastSoldPrice`、`sqft` 三个字段进行异常值裁剪，这些字段与房价预测密切相关，且容易出现极端值。

### 2.3.3 类别变量编码

对于类别型变量，项目采用 One-Hot 编码方式，将离散类别转化为机器学习模型可处理的数值特征。主要编码字段包括 `type`、`sub_type`、`zip`。其中，`type` 和 `sub_type` 表示房屋类型相关信息，`zip` 表示邮编或区域信息。地理位置对房价影响较大，因此邮编编码后能够为模型提供重要的区域特征。

### 2.3.4 数值特征标准化

项目对部分数值特征使用 `StandardScaler` 进行标准化，使其均值接近 0、标准差接近 1。标准化能够降低不同量纲对模型训练的影响，尤其对线性模型和神经网络模型较为重要。经过结构化预处理后，最终共有 10,893 条样本，去除目标变量和部分非特征字段后，共得到 882 个结构化特征。

## 2.4 文本数据预处理

文本数据预处理主要由 `src/data/preprocess_text.py` 完成。文本处理包括文本清洗、TF-IDF 特征提取、SVD 降维和 BERT 向量生成。

### 2.4.1 文本清洗

原始房源描述文本可能包含大小写混合、标点符号、无意义字符、停用词等内容。项目对文本进行了如下处理：(1) 将文本统一转为小写；(2) 使用分词工具进行英文分词；(3) 去除停用词；(4) 去除非字母 token；(5) 对空值文本进行空字符串处理。

### 2.4.2 TF-IDF 特征提取与降维

TF-IDF 是经典文本特征表示方法，能够衡量词语在单个文档中的重要程度以及在整个语料中的区分能力。本项目使用 TF-IDF 提取房源描述中的关键词统计特

征。由于原始 TF-IDF 特征维度较高，项目进一步使用 TruncatedSVD 进行降维，最终得到 128 维文本特征。TF-IDF 特征适合捕捉房源描述中的关键词信息，例如“renovated”“garage”“pool”“waterfront”“school”等。

### 2.4.3 BERT 语义向量提取

除了 TF-IDF，项目还使用 BERT 模型提取文本语义向量。BERT 能够通过上下文建模捕捉文本中的深层语义信息，相比传统词袋模型更适合表达句子和段落级语义。项目使用 `bert-base-uncased` 模型，对每条房源描述生成 768 维语义向量。BERT 特征可以在一定程度上表达房源描述中的整体语义，例如房屋品质、环境优势、装修风格等。

## 2.5 数据集划分

真实实验中，项目按照 80%、10%、10% 的比例将数据划分为训练集、验证集和测试集：

表 2: 数据集划分

| 数据集 | 样本数   |
|-----|-------|
| 训练集 | 8,714 |
| 验证集 | 1,089 |
| 测试集 | 1,090 |

训练集用于模型训练，验证集用于模型选择和调参，测试集用于最终性能评估。当前实验使用随机划分，并设置随机种子为 42，以保证实验可复现。

## 3 模型设计

本项目构建了三类模型：结构化基线模型、文本基线模型和多源融合模型。通过对比这些模型，可以分析不同数据模态以及不同融合策略对房价预测效果的影响。

### 3.1 结构化基线模型

结构化基线模型仅使用房屋结构化属性作为输入。项目实现了三个结构化模型。

#### 3.1.1 LinearBaseline

LinearBaseline 是线性回归基线模型。该模型假设输入特征与房价之间存在线性关系，优点是训练速度快、可解释性较强，适合作为最基础的结构化数据预测基线。

在线性模型中，每个特征对应一个权重，模型通过学习这些权重来预测房价。虽然线性模型表达能力有限，但当结构化特征经过充分编码后，仍然能够取得较稳定的效果。

### 3.1.2 RandomForestBaseline

RandomForestBaseline 使用随机森林回归模型。随机森林通过训练多棵决策树并对结果进行集成，可以建模非线性关系，并具有一定的抗过拟合能力。随机森林适合处理表格数据，也能够刻画特征之间的复杂关系。

### 3.1.3 XGBoostBaseline

XGBoostBaseline 使用梯度提升树模型。XGBoost 是结构化数据建模中常用的强基线方法，能够通过逐步拟合残差提升模型预测能力。它适合处理非线性关系，并在许多表格数据任务中表现良好。在本项目中，XGBoostBaseline 用于检验结构化特征在强机器学习模型下的预测能力。

## 3.2 文本基线模型

文本基线模型仅使用房源描述文本特征作为输入。项目实现了两个文本模型。

### 3.2.1 TfidfRidgeBaseline

TfidfRidgeBaseline 使用 TF-IDF 降维特征作为输入，并使用 Ridge 回归进行房价预测。Ridge 回归在线性回归基础上加入 L2 正则化，有助于缓解高维文本特征带来的过拟合问题。该模型能够检验房源描述中的关键词信息是否对价格预测有帮助。

### 3.2.2 BERTMLPBaseline

BERTMLPBaseline 使用 BERT 语义向量作为输入，并通过多层感知机进行回归预测。BERT 向量包含更丰富的上下文语义信息，理论上可以捕捉房源描述中的深层语义。不过，BERT 向量如果只作为预计算特征使用，而不针对房价预测任务进行端到端微调，可能无法充分适配具体预测目标。

## 3.3 多源融合模型

多源融合模型同时使用结构化特征和文本特征。项目实现了早期融合、中期融合和晚期融合三类策略。

### 3.3.1 早期融合模型

早期融合是在输入层直接将结构化特征与文本特征拼接，然后输入到统一模型中进行训练。项目中的特征拼接由 `src/features/fusion.py` 中的 `concat_features` 函数完成。本项目实现了两个早期融合模型：**EarlyFusionXGBoost**（将拼接后的多源特征输入 XGBoost 模型）和 **EarlyFusionMLP**（将拼接后的多源特征输入多层感知机）。早期融合的优点是实现简单，并且模型可以直接在输入层学习不同模态特征之间的组合关系。

### 3.3.2 中期融合模型

中期融合先分别对结构化特征和文本特征进行编码，再在中间表示层进行融合。本项目实现了 `MidFusionModel`，其核心思想是使用双塔结构分别处理结构化模态和文本模态，然后通过注意力机制或中间表示融合方式学习两类模态之间的关系。相比早期融合，中期融合能够保留不同模态各自的特征表达，再在更高层次进行交互，适合处理不同模态特征维度差异较大的情况。

### 3.3.3 晚期融合模型

晚期融合先分别训练不同模态的模型，再融合各模型的预测结果。本项目实现了 `LateFusionStacking`，其第一层包括结构化模型和文本模型，第二层使用 Ridge 回归作为元学习器，对不同模型的预测结果进行集成。晚期融合的优点是模块独立性强，便于组合不同模型；缺点是它主要融合预测结果，而不是直接融合原始特征或中间表示，因此对不同模态之间深层交互关系的建模能力相对有限。

## 4 实验设计

### 4.1 实验流程

本项目完整实验流程如下：

步骤 1: 加载处理后的结构化特征、TF-IDF 文本特征和 BERT 文本特征；

步骤 2: 读取目标变量 `lastSoldPrice`；

步骤 3: 按照 80%、10%、10% 划分训练集、验证集和测试集；

步骤 4: 创建 9 个待比较模型；

步骤 5: 依次训练每个模型；

步骤 6: 在训练集、验证集和测试集上计算评价指标；

步骤 7: 将实验结果保存到 `results/experiment_log.csv`;

步骤 8: 输出测试集模型性能汇总和最佳模型。

完整实验运行命令为:

```
python src/pipeline/run_pipeline.py
```

真实实验已经成功跑通, 9 个模型全部完成训练和评估。

## 4.2 评价指标

本项目采用 RMSE、MAE、 $R^2$  和 MAPE 作为回归任务评价指标。

**RMSE (均方根误差):** 反映预测值与真实值之间的平均偏差。由于平方项会放大较大误差, 因此 RMSE 对大误差更敏感。在房价预测中, RMSE 可以反映模型在高价房或异常样本上的误差情况。

**MAE (平均绝对误差):** 表示预测价格与真实价格之间的平均绝对差值。相比 RMSE, MAE 对极端误差不那么敏感, 更容易从业务角度解释。

**$R^2$  (决定系数):** 表示模型对目标变量方差的解释能力。 $R^2$  越接近 1, 说明模型拟合效果越好。对于房价预测任务,  $R^2$  能够反映模型整体解释房价变化的能力。

**MAPE (平均绝对百分比误差):** 用于衡量相对误差。但在房价数据中, 如果真实价格存在较小值或异常低价交易, MAPE 会被显著放大。因此, 本项目主要以 RMSE、MAE 和  $R^2$  作为核心指标, MAPE 作为辅助参考。

## 4.3 工程化 Pipeline

为了提升项目的可复现性和交付质量, 本项目新增统一 Pipeline 入口 `src/pipeline/run_pipeline.py`。该入口支持三种运行方式:

- (1) **检查模式:** `python src/pipeline/run_pipeline.py --check-only`, 只检查项目结构和真实数据文件是否完整, 不进行模型训练。
- (2) **Smoke 测试模式:** `python src/pipeline/run_pipeline.py --smoke`, 使用小规模合成数据运行完整流程, 用于快速验证代码链路、模型接口和结果写入功能是否正常。
- (3) **真实数据完整实验模式:** `python src/pipeline/run_pipeline.py`, 使用 `data/processed` 下的真实处理后数据运行完整训练和评估流程。

本项目还通过 `pytest` 对评估模块进行了测试, 测试结果为 14 passed, 说明评估指标、显著性检验和可视化辅助函数均能够正常运行。

## 5 实验结果与分析

### 5.1 数据规模与特征维度

真实实验运行时，数据加载与特征维度如表 3 所示。

表 3: 实验数据规模与特征维度

| 项目          | 数值     |
|-------------|--------|
| 样本数量        | 10,893 |
| 结构化特征维度     | 882    |
| TF-IDF 特征维度 | 128    |
| BERT 特征维度   | 768    |
| 训练集样本数      | 8,714  |
| 验证集样本数      | 1,089  |
| 测试集样本数      | 1,090  |

### 5.2 全部模型测试集结果

完整实验共训练并评估 9 个模型，测试集结果如表 4 和图 1 所示。

表 4: 全部模型测试集性能对比

| 模型                    | 模态          | Test RMSE         | Test MAE         | Test $R^2$    | Test MAPE |
|-----------------------|-------------|-------------------|------------------|---------------|-----------|
| LinearBaseline        | 结构化         | 138,423.67        | 98,183.64        | 0.7436        | 404.47%   |
| RandomForestBaseline  | 结构化         | 164,139.78        | 110,770.61       | 0.6394        | 333.82%   |
| XGBoostBaseline       | 结构化         | 142,935.02        | 99,872.33        | 0.7266        | 373.78%   |
| TFIDFRidgeBaseline    | 文本          | 175,620.82        | 132,936.36       | 0.5872        | 501.76%   |
| BERTMLPBaseline       | 文本          | 207,416.99        | 153,539.88       | 0.4242        | 709.94%   |
| EarlyFusionXGBoost    | 早期融合        | 128,782.09        | 89,025.91        | 0.7780        | 195.86%   |
| <b>EarlyFusionMLP</b> | <b>早期融合</b> | <b>107,725.39</b> | <b>71,498.85</b> | <b>0.8447</b> | 228.71%   |
| MidFusionModel        | 中期融合        | 118,124.42        | 78,640.47        | 0.8133        | 322.44%   |
| LateFusionStacking    | 晚期融合        | 137,794.58        | 95,168.52        | 0.7459        | 336.58%   |




图 1: 单模态基线模型在 RMSE、MAE、 $R^2$ 、MAPE 四个指标上的对比

从表 4 可以看出, 最佳模型为 **EarlyFusionMLP**, 其 Test RMSE = 107,725.39, Test MAE = 71,498.85, Test  $R^2$  = 0.8447。全部三个融合模型的 Test  $R^2$  均超过最佳单模态模型, 验证了多源数据融合的有效性。

### 5.3 单模态基线评估

为深入理解结构化特征与文本特征各自的预测能力, 本文对 5 个单模态基线模型进行了系统对比。图 1 展示了四个指标的对比情况。结构化模型 (蓝色) 在所有指标上均优于文本模型 (橙色)。LinearBaseline 是表现最好的结构化单模态模型, RMSE 为 138,423.67,  $R^2$  为 0.7436。BERTMLPBaseline 的测试集表现最差, RMSE 高达 207,416.99, 但其训练集  $R^2$  为 0.7501, 说明该模型存在明显的过拟合问题。




图 2: 预测值与真实值散点图（全部五个单模态模型，2×3 布局）

图 2 展示了 LinearRegression、XGBoost、RandomForest、TF-IDF+Ridge 和 BERT+MLP 五个单模态模型的预测值与真实值散点图。红色虚线表示理想预测线 ( $y = \hat{y}$ )。LinearRegression 的散点沿对角线集中度最高 (RMSE = 138,424,  $R^2 = 0.7436$ ), 为最佳结构化单模态模型; XGBoost 次之 (RMSE = 142,935)。BERT+MLP 在低价格区间倾向于高估、在高价格区间倾向于低估, 文本模型整体离散度大于结构化模型。

各模型残差的标准差 (Std) 反映了预测的波动程度, 偏度 (Skew) 指示了系统性偏差的方向。残差大致呈零均值对称分布, 说明模型不存在系统性高估或低估偏差。

结构化特征组的平均 RMSE 为 148,499.49, 平均  $R^2$  为 0.7032; 文本特征组的平均 RMSE 为 191,518.91, 平均  $R^2$  为 0.5057。结构化特征的平均 RMSE 比文本特征低约 22.5%, 说明在当前的实验数据上, 结构化房屋属性仍是房价预测的主要信息源, 单独使用文本特征无法达到可比精度。

#### 5.4 消融实验：各模态增量贡献

为量化每个模态对最终预测性能的增量贡献, 本节进行消融实验, 对比仅结构化、仅文本、早期融合、中期融合和晚期融合五种条件。




图 3: 消融实验：五种模态组合在四个指标上的平均表现

图 3 展示了消融实验结果。早期融合策略在所有指标上均取得最优表现，晚期融合策略的表现相对于早期融合和中期融合较弱。仅文本模态的 RMSE 最高、 $R^2$  最低，说明文本特征虽提供增量信息，但无法独立支撑精确的房价预测。

在 Early Fusion 列中，MLP（107,725.39）明显优于 XGBoost（128,782.09），说明深度网络在拼接特征场景下具有更强的建模能力。

以最佳结构化模型 LinearBaseline（RMSE = 138,423.67）为基准，EarlyFusion-MLP 的 RMSE 降低了 22.0%，MidFusionModel 降低了 14.7%，LateFusionStacking 仅降低了 0.5%。文本信息的增量贡献在早期融合中被最充分地利用。

消融实验的量化结果如表 5 所示。

表 5: 消融实验：各模态组合的最佳模型与增量贡献

| 消融条件 | 最佳模型               | RMSE       | $R^2$  | 相比最佳结构化 |
|------|--------------------|------------|--------|---------|
| 仅结构化 | LinearBaseline     | 138,423.67 | 0.7436 | 基线      |
| 仅文本  | TFIDFRidgeBaseline | 175,620.82 | 0.5872 | -26.9%  |
| 早期融合 | EarlyFusionMLP     | 107,725.39 | 0.8447 | +22.0%  |
| 中期融合 | MidFusionModel     | 118,124.42 | 0.8133 | +14.7%  |
| 晚期融合 | LateFusionStacking | 137,794.58 | 0.7459 | +0.5%   |

## 5.5 显著性检验

为验证模型间性能差异的统计显著性，本文采用 Wilcoxon 配对符号秩检验对关键模型对进行假设检验。检验基于测试集 1,090 个样本上各模型的逐样本绝对误差。

Wilcoxon 配对符号秩检验的主要结论如下：

XGBoost 与 TFIDF+Ridge 之间的差异极其显著 ( $p < 0.001$ )，说明结构化特征与文本特征的单模态建模能力存在本质差异。LinearBaseline 与 EarlyFusionMLP 之间差异显著 ( $p < 0.001$ )，验证了融合模型相比最佳单模态模型的提升具有统计意义。EarlyFusionXGBoost 与 EarlyFusionMLP 之间差异显著 ( $p < 0.001$ )，说明在早期融合策略下，MLP 能够比 XGBoost 更好地利用拼接后的多源特征。MidFusion 与 LateFusionStacking 之间差异显著 ( $p < 0.001$ )，印证了中期注意力融合优于晚期预测级融合的结论。

## 5.6 特征重要性分析




图 4: XGBoost 和 RandomForest 的 Top 20 特征重要性

图 4 展示了两个树模型在全体 882 个结构化特征中最重要 20 个特征。两个模型在重要特征的排序上存在较高一致性，房屋面积相关特征（如 sqft）和地理位置编码特征（zip 相关 One-Hot 列）位居前列。XGBoost 的 importance 分布比 RandomForest 更集中于少数 top 特征，这与梯度提升树倾向于将信息集中到少数分裂节点的特性一致。

## 5.7 错误分析

为进一步理解模型的预测行为，本节从多个维度对预测错误进行深入分析。

所有模型的绝对误差均随价格区间升高而递增，高价格区间（>50 万美元）的预测难度显著大于低价格区间。EarlyFusionMLP 在所有价格区间上的 MAE 和 RMSE 均为最低，尤其是在高价格区间，其优势更加明显。




图 5: 全部 7 个模型预测误差（残差）的箱线图分布

图 5 用箱线图展示了全部 7 个模型的预测误差分布特征。EarlyFusionMLP 的箱体最窄（ $IQR = 89,974$ ），中位数最接近零线，说明其预测最为稳定；MidFusion 次之（ $IQR = 92,564$ ）。LinearReg 作为最佳结构化模型， $IQR = 135,448$ ，优于 XGBoost（ $IQR = 140,189$ ）和 RandomForest（ $IQR = 145,106$ ）。TFIDF+Ridge 的箱体最宽（ $IQR = 208,340$ ），异常值延伸最远。LateFusion 的误差分布介于结构化模型和融合模型之间（ $IQR = 123,341$ ），反映了其作为预测级融合的保守特性。所有模型均呈现出不同程度的异方差性——残差在高价区扩大。相关性检验显示，各模型的 | 误差 | 与真实价格的 Pearson 相关系数在 0.18–0.35 之间，属于中轻度异方差性，对模型比较结论不构成根本影响。

## 5.8 关于 MAPE 指标的说明

实验结果中，各模型的 MAPE 普遍较高。例如，EarlyFusionMLP 的 Test MAPE 为 228.71%。这并不说明模型失效，而可能与房价数据的分布特征有关。MAPE 的计算将误差除以真实值，当真实成交价格较小时，即使绝对误差不大，也可能导致百分比误差非常高。因此，本文在分析模型优劣时，主要参考 RMSE、MAE 和  $R^2$ ，MAPE 作为辅助参考指标。

# 6 工程实现与项目交付

## 6.1 项目结构

本项目采用模块化工程结构，完整代码可在 GitHub 查看：<https://github.com/steve26456d/multi-source-house-price-prediction>。主要目录如下：

```
multi-source-house-price-prediction/
  config/                # 项目配置文件
  data/                  # 原始数据和处理后数据
  notebooks/             # 探索性分析 Notebook
  src/
    data/                # 数据预处理与划分
    features/            # 特征融合
    models/              # 模型实现
    evaluation/          # 评估指标、显著性检验、可视化
    pipeline/            # 端到端 Pipeline
    experiment_runner.py
  tests/                 # 单元测试
  results/               # 实验结果输出
  README.md
  requirements.txt
  environment.yaml
```

这种结构将数据处理、模型实现、评估分析和 Pipeline 入口分离开来，便于多人协作开发，也方便后续维护和扩展。

## 6.2 Pipeline 构建

作为统一的 Pipeline 文件 `src/pipeline/run_pipeline.py`，其主要功能包括：

- (1) 检查项目目录结构是否完整；
- (2) 检查配置文件 `config/config.yaml` 是否存在；
- (3) 检查真实数据模式下所需的处理后数据文件是否存在；
- (4) 创建 `results` 和 `models` 输出目录；
- (5) 支持 Smoke 模式快速验证工程链路；
- (6) 调用 `src/experiment_runner.py` 中已有实验流程；
- (7) 输出实验结果并保存到 `results/experiment_log.csv`。

通过该 Pipeline，项目可以使用统一命令运行，而不需要手动逐个执行数据加载、模型训练和评估脚本。

### 6.3 可复现性设计

项目通过以下方式提升可复现性：

- (1) 使用 `environment.yaml` 和 `requirements.txt` 管理环境依赖；
- (2) 使用固定随机种子 42 进行数据划分；
- (3) 将实验结果统一保存到 `results/experiment_log.csv`；
- (4) 提供 `--check-only` 模式避免因路径或数据缺失导致运行失败；
- (5) 提供 `--smoke` 模式在无真实数据时快速验证代码链路；
- (6) 使用 `pytest` 对评估模块进行单元测试（14 passed）。

### 6.4 测试结果

项目当前单元测试结果为 14 passed，测试覆盖了评估指标计算、异常输入处理、显著性检验辅助函数以及可视化辅助函数。测试通过说明项目评估模块具有较好的稳定性，能够支撑后续实验分析。

## 7 小组分工

本项目由四位成员协作完成，具体分工如下：

表 6: 团队成员分工

| 角色       | 成员  | 核心职责                         |
|----------|-----|------------------------------|
| 数据工程负责人  | 陈晓英 | 多源数据采集清洗、特征工程、数据融合对齐         |
| 算法负责人    | 孙钰淼 | 多模态融合模型设计、模型实现与调优、对比实验       |
| 评估与分析负责人 | 石韞嘉 | 评估体系设计、消融实验、可视化与错误分析         |
| 工程与交付负责人 | 潘志强 | 代码整合与模块化、Pipeline 构建、报告/答辩材料 |

### 7.1 数据工程工作

数据工程负责人主要完成多源数据的获取、清洗和预处理工作。具体包括结构化数据缺失值填补、异常值处理、类别变量编码、数值特征标准化，以及文本字段清洗、TF-IDF 特征提取、SVD 降维和 BERT 文本向量生成。数据工程部分为后续算法建模提供了统一、可用的输入数据。

## 7.2 算法建模工作

算法负责人主要负责模型设计、实现和调优。项目中实现了结构化基线模型、文本基线模型以及早期融合、中期融合、晚期融合模型。通过多个模型的对比实验，验证了不同模态和不同融合策略对房价预测效果的影响。

## 7.3 评估分析工作

评估与分析负责人主要负责评价体系设计、实验结果分析、可视化与错误分析。项目中实现了 RMSE、MAE、 $R^2$ 、MAPE 等回归评价指标，并提供了显著性检验和可视化辅助函数，为模型效果比较和实验结论提供支持。

## 7.4 工程交付工作

工程与交付负责人主要负责最终代码整合、模块化整理、Pipeline 构建和交付材料准备。具体工作包括基于已有的数据、模型和评估模块新增统一 Pipeline 入口，保证项目能够通过一条命令完成真实数据实验运行；同时完善 README 运行说明，整理实验结果，并撰写报告和答辩材料。

# 8 结论与展望

## 8.1 研究结论

本项目围绕多源数据融合房价预测任务，系统比较了结构化模型、文本模型和多源融合模型的表现。实验结果表明：

- (1) **结构化特征是房价预测的主要信息来源。** XGBoostBaseline 等结构化模型整体表现优于单独文本模型，测试  $R^2$  达到 0.7266，说明房屋面积、房型、区域、建造年份等结构化属性对房价具有较强解释能力。
- (2) **单独文本模型效果相对有限。** TFIDFRidgeBaseline 和 BERTMLPBaseline 的表现弱于结构化基线。但文本模型与结构化模型的误差相关性较低 ( $r \approx 0.5-0.6$ )，说明文本特征捕捉到了结构化特征未能表达的补充性信息，这些信息在融合模型中被有效利用。
- (3) **多源融合能够显著提升模型性能。** EarlyFusionMLP 在测试集上取得最佳结果，RMSE 为 107,725.39， $R^2$  为 0.8447，相比最佳单模态结构化模型 LinearBaseline (RMSE = 138,423.67) 的 RMSE 降低 22.0%。Wilcoxon 显著性检验 ( $p < 0.001$ ) 验证了该提升的统计可靠性。

- (4) **早期融合在本项目中表现最好。**通过在输入层直接拼接结构化特征和文本特征，EarlyFusionMLP 能够学习不同模态之间的组合关系，效果优于中期双塔注意力和晚期 Stacking 集成策略。
- (5) **错误分析揭示了模型的异方差性和系统性偏差特征。**所有模型均存在残差随价格扩大的异方差性，高价格区间绝对误差大但相对误差小。EarlyFusionMLP 在系统性偏差控制方面优于所有基线模型。
- (6) **工程化 Pipeline 对项目交付具有重要作用。**项目实现了端到端的可运行流程，并通过 pytest 对评估模块进行了 14 项单元测试，确保评估体系的可靠性。

## 8.2 不足之处

本项目仍存在以下不足：

- (1) 房价数据可能存在异常低价样本或特殊交易记录，导致 MAPE 指标偏高。后续可进一步进行异常样本分析和更严格的数据清洗。
- (2) 文本特征仍有提升空间。当前 BERT 向量主要作为预计算语义特征使用，未针对房价预测任务进行端到端微调，因此语义特征与预测目标之间可能存在一定差距。
- (3) 当前实验主要使用结构化数据和文本数据两类模态，尚未引入图像、地图、学校评分、社区犯罪率、交通距离等更多外部信息。房价受地理和环境因素影响很大，未来加入空间信息可能进一步提升模型效果。
- (4) 当前实验使用一次随机划分进行模型比较，后续可引入交叉验证或多随机种子实验，使结果更加稳健。

## 8.3 后续改进方向

后续可从以下方面继续改进：

- (1) 加强异常值检测，对极端低价和极端高价样本进行单独分析；
- (2) 引入地理位置特征，例如经纬度、学校距离、商圈距离、海岸线距离等；
- (3) 对 BERT 或其他预训练语言模型进行任务微调；
- (4) 尝试更强的多模态融合结构，例如 Cross-Attention、Transformer Fusion 等；
- (5) 完善配置化实验管理，使模型参数、数据路径和输出路径更加统一；
- (6) 使用多次重复实验或交叉验证，提高实验结论的可靠性。

总体来看, 本项目完成了从多源数据预处理、特征提取、融合建模、模型评估到工程化 Pipeline 交付的完整流程。实验结果验证了结构化房屋属性与文本描述信息之间的互补性, 说明多源异构数据融合能够有效提升房价预测性能, 达到了课程项目对数据挖掘分析、模型比较和工程实现的综合要求。

## 参考文献

- [1] Kaggle. Florida Real Estate Sold Dataset 2026. <https://www.kaggle.com/datasets/kanchana1990/florida-real-estate-sold-dataset-2026>
- [2] Ahmed, E. & Moustafa, M. (2016). House price estimation from visual and textual features. *Proceedings of IJCNN 2016*.
- [3] Poursaeed, O., Matera, T., & Belongie, S. (2018). Vision-based real estate price estimation. *Machine Vision and Applications*, 29(4), 667–676.
- [4] Law, S., Paige, B., & Russell, C. (2019). Take a look around: Using street view and satellite images to predict house prices. *ACM TIST*, 10(5), 1–19.
- [5] Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. *Proceedings of NAACL-HLT 2019*.
- [6] Chen, T. & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of ACM SIGKDD 2016*.
- [7] 项目      GitHub      仓库:      <https://github.com/steve26456d/multi-source-house-price-prediction>