

团队分工声明

Team Division Declaration • Multi-Source House Price Prediction

项目仓库: <https://github.com/steve26456d/multi-source-house-price-prediction>

一、项目概述

本项目为《数据分析与挖掘》课程期末大作业——多源房价预测（Multi-Source House Price Prediction）。项目以 Florida Real Estate Sold 2026 数据集（来源: Kaggle, 样本数 10,893）为核心实验数据, 该数据集同时包含结构化房屋属性（如面积、卧室数、建造年份等）与非结构化房源描述文本, 是天然的多模态数据源, 适合验证多源数据融合在房价预测任务中的有效性。

项目从该数据集中分别提取结构化特征（882 维）与文本特征（TF-IDF 128 维 + BERT 768 维），构建了结构化基线模型、文本基线模型，以及早融合（Early Fusion）、中融合（Mid Fusion）、晚融合（Late Fusion）三种多模态融合策略, 共训练并评估 9 个模型。最终 EarlyFusionMLP 取得最优结果（Test RMSE: 108,014.78, Test R^2 : 0.8439），验证了多源融合相比单一模态的显著提升。

本团队共 4 名成员, 分工明确、协作紧密。以下基于 GitHub 仓库提交记录, 逐条列出每位成员的具体贡献。

二、团队成员总览

姓名	GitHub	角色	工作量
孙钰淼	steve26456d	项目负责人 / 模型开发与集成	25%
潘志强	littpan	工程与交付负责人 / 报告主笔	25%
石韞嘉	feralweeds	评估与分析负责人	25%
陈晓英	cintychens	数据工程负责人	25%

三、成员详细分工

孙钰淼（孙钰淼） • GitHub: @steve26456d

角色定位：项目负责人，负责项目整体架构设计、多模态融合模型设计开发、CI/CD 配置、文档整合与 LaTeX 排版。

代码文件贡献：

- 项目框架搭建：src/ 完整目录架构、setup.cfg、requirements.txt、environment.yml、.env.example、config/config.yml 等基础配置文件。
- 基线模型（W14）：src/models/base.py（模型基类）、src/models/structured_baseline.py（结构化数据基线模型，含 Linear / RandomForest / XGBoost）、src/models/text_baseline.py（文本数据基线模型，含 TF-IDF + Ridge / BERT + MLP）。
- 融合模型（W15）：src/models/early_fusion.py（早融合：拼接 + XGBoost/MLP）、src/models/mid_fusion.py（中融合：双塔 + 注意力机制）、src/models/late_fusion.py（晚融合：Stacking 集成）、src/models/hyperparam_tuning.py（超参数调优）、src/models/__init__.py。
- 评估指标：src/evaluation/metrics.py（RMSE/MAE/R²/MAPE 指标，与石韞嘉协作）。
- 实验运行器：src/experiment_runner.py（与石韞嘉协作）。
- CI/CD：.github/workflows/pylint.yml（代码质量自动检查）、setup-python v5 升级、Python 3.10 版本限定。
- 测试支撑：tests/conftest.py（测试夹具修复与完善）。
- 数据管理：data/raw/Florida/ 原始数据导入、data/processed/ 处理后特征文件（Git LFS 管理）。
- 基线实验输出：notebooks/03_baseline_results.ipynb。

文档贡献：

- doc/interface_spec.md — 模块接口规范文档。
- doc/TODO.md — 项目任务规划与进度跟踪。
- README.md — 项目说明文档（与潘志强协作）。
- .gitignore — LaTeX 模板 ignore 规则。
- Report.tex — LaTeX 报告源码。
- LICENSE — 项目开源许可。

报告章节贡献：

- 报告统稿与 LaTeX 排版重构（Report.tex → Report.pdf）。
- 项目框架与实验设计相关章节。
- 基线模型（结构化基线 5 个、文本基线 2 个）实验设计与结果分析。
- 多模态融合模型（早/中/晚融合 3 个）设计与对比实验分析。
- 超参数调优策略与消融实验结果。

工作量占比：25%

潘志强（潘志强） · GitHub: @littpan

角色定位：工程与交付负责人，负责端到端 Pipeline 集成开发、项目报告主体撰写与 README 文档整理。

代码文件贡献：

- 实验管道 (Pipeline)：src/pipeline/run_pipeline.py — 项目统一运行入口，支持三种模式：① --check-only（项目结构与数据文件完整性检查）、② --smoke（模拟数据快速冒烟测试，验证全流程可跑通）、③ 默认运行（加载真实处理后数据，完成训练/评估/结果输出全流程）。该模块串联了数据加载、预处理、特征工程、模型训练、评估与结果保存的端到端流程，是项目可复现性的核心保障。

文档贡献：

- README.md — 与孙钰淼协作完成项目文档整理（含快速开始、Pipeline 入口、实验结果等章节）。
- Report.md — 报告 Markdown 初稿撰写（摘要、引言、方法论等核心叙述）。
- Report.pdf — 报告初版生成。

报告章节贡献：

- 报告主体文字撰写（摘要、引言、方法论说明等核心叙述）。
- 项目背景与研究动机（1.1 - 1.3 节）。
- 端到端 Pipeline 流程设计与工程实现描述。
- README 项目文档（快速开始、使用方法、实验结果概览）。

工作量占比：25%

石韞嘉（石韞嘉） · GitHub: @feralweeds

角色定位：评估与分析负责人，负责模型评估指标体系设计、统计显著性检验、结果可视化、实验 Runner smoke 模式支持及正式实验结果产出。

代码文件贡献：

- 评估模块核心：src/evaluation/__init__.py（模块初始化）、src/evaluation/metrics.py（评估指标计算，与孙钰淼协作）、src/evaluation/significance_test.py（配对 t 检验与 Wilcoxon 检验）、src/evaluation/visualization.py（模型性能对比图、显著性热力图等）。
- 评估模块测试：tests/test_evaluation_metrics.py、tests/test_significance_test.py、tests/test_visualization_helpers.py（共 3 个测试文件，保障评估逻辑正确性）。
- 实验流程增强：src/experiment_runner.py — smoke 模式支持，实现小规模模拟数据的快速集成测试。
- 模型 smoke 适配：src/models/early_fusion.py、src/models/late_fusion.py、src/models/structured_baseline.py — 为 smoke 模式添加适配逻辑，确保快速验证流程可用。

文档贡献：

- doc/evaluation_metrics.md — 评估指标体系详细说明（RMSE/MAE/R²/MAPE）。

- `doc/evaluation_experiment_plan.md` — 评估实验方案设计（单模态基线、融合对比、消融实验、显著性检验）。
- `doc/analysis_report.md` — 评估分析综合报告。
- `doc/shiyunjia_work_plan.md` — 个人任务规划与进度说明。
- `doc/TODO.md` — 与孙钰淼协作更新任务列表。

报告章节贡献：

- 评估指标体系章节（RMSE、MAE、 R^2 、MAPE 定义与计算方式）。
- 统计显著性检验章节（配对 t 检验、Wilcoxon 检验方法与结果）。
- 模型对比实验（9 个模型）结果汇总与分析。
- 结果可视化（模型性能对比图、显著性热力图等）。
- 正式实验结果产出包（`submission/shiyunjia_evaluation_results/`: `experiment_log.csv` + `model_ranking.csv`）。

工作量占比：25%

陈晓英（陈晓英） · [GitHub: @cintychens](#)

角色定位：数据工程负责人，负责 Florida 数据集探索性分析、结构化/文本数据预处理 Pipeline 开发、特征融合接口实现与训练/验证/测试集划分。

代码文件贡献：

- 数据探索分析（W13）：`notebooks/01_ames_eda.ipynb` — Ames Housing Dataset 探索性数据分析（项目初期探索，后因聚焦 Florida 数据集而不再作为主实验数据源）。
- `notebooks/02_florida_eda.ipynb` — Florida Real Estate Sold 2026 探索性数据分析（描述统计、缺失值分析、价格分布、文本特征分布等）。
- 数据预处理（W14）：`src/data/preprocess_structured.py` — 结构化数据预处理 Pipeline（缺失值中位数/众数填补、IQR 异常值裁剪、One-Hot 编码、StandardScaler 标准化）。
- `src/data/preprocess_text.py` — 文本数据预处理 Pipeline（文本清洗、分词、TF-IDF 向量化、BERT 语义嵌入提取）。
- `src/data/__init__.py` — 数据模块初始化。
- 特征融合与数据划分（W15）：`src/features/fusion.py` — 多模态特征融合接口实现（早融合拼接、中融合双塔对齐、晚融合独立特征准备）。
- `src/features/__init__.py` — 特征模块初始化。
- `src/data/split.py` — 训练集/验证集/测试集划分（8:1:1 比例，分层采样确保价格分布一致）。

文档贡献：

- `doc/data_alignment.md` — Florida 数据集结构化与文本模态对齐策略文档。

- `doc/feature_engineering.md` — 特征工程详细说明（TF-IDF 参数、BERT 模型选择、降维策略）。
- `doc/data_lineage.md` — 数据血缘关系图（原始数据 → 预处理 → 特征 → 模型输入）。

报告章节贡献：

- Florida Real Estate Sold 2026 数据集探索分析章节（描述统计、分布可视化）。
- 结构化数据预处理 Pipeline 设计章节（缺失值处理、异常值处理、编码与标准化）。
- 文本数据预处理 Pipeline 设计章节（文本清洗、TF-IDF 与 BERT 特征提取）。
- 多模态特征融合接口设计章节（早/中/晚融合模式的特征拼接与对齐策略）。
- 训练/验证/测试集划分策略说明（8:1:1 分层采样）。
- 数据对齐策略与数据血缘关系说明。

工作量占比：25%

四、工作量汇总

姓名	GitHub	核心代码文件	文档数	报告章节	工作量
孙钰淼	steve26456d	15+	7+	5	25%
潘志强	littpan	1	3	4	25%
石韞嘉	feralweeds	9	5	5	25%
陈晓英	cintychens	9	3	6	25%

说明：虽然各成员贡献的代码文件数量有所差异，但每位成员在各自模块中均承担了从设计、实现到文档撰写的完整工作。代码文件数量差异反映了不同模块的技术复杂性不同——潘志强负责的 Pipeline 模块虽仅 1 个文件，但承担了全流程串联与项目可复现性的核心职责；孙钰淼负责的模型模块涵盖 9 个模型的完整实现与调优；石韞嘉负责的评估模块包含指标体系、显著性检验与可视化的完整闭环；陈晓英负责的数据模块覆盖从原始数据到特征输出的全链路。综合考量代码贡献、文档撰写、报告章节与团队协作，全体成员一致认可每位成员工作量占比均为 25%。

全体成员签名确认：

本文档基于 GitHub 仓库 <https://github.com/steve26456d/multi-source-house-price-prediction> 的提交记录生成，所有贡献信息均可通过 `git log` 验证。